

UNIVERSITÀ DEGLI STUDI DI SALERNO

DIPARTIMENTO DI INFORMATICA

Corso di Laurea Magistrale



Progetto Strumenti Formali per la Bioinformatica

FCGR E SIAMESE NETWORKS PER L'ANALISI DI SIMILARITÀ DI ECCDNA

Docenti

De Felice Clelia
Zaccagnino Rocco
Zizza Rosalba

Studente

Simonetti Daria
NF22500066

Anno Accademico 2025/2026

Abstract

In questo progetto viene studiato l'impiego della *Frequency Chaos Game Representation* (FCGR) e delle reti neurali Siamese per associare sequenze di DNA extracromosomico circolare (eccDNA) a differenti condizioni biologiche e tumorali. Il task finale comprende 11 classi tumorali e la classe Healthy. La pipeline principale trasforma ogni sequenza in una FCGR con $k = 6$ e utilizza poi una CNN condivisa all'interno di una Siamese Network per apprendere embedding L2-normalizzati di 128 dimensioni. Il training è basato su Euclidean Contrastive Loss e Dynamic Semi-Hard Negative Mining; in inferenza, la classe viene associata mediante cosine similarity rispetto a una reference bank di embedding di training. In seguito al confronto sperimentale iniziale con downsampling, è stata introdotta una seconda Siamese addestrata sull'intero training set mediante balanced batch sampling. Inoltre, come richiesto per verificare il reale vantaggio del metric learning, è stata sviluppata una baseline CNN multiclass diretta con la stessa FCGR e lo stesso backbone. I risultati mostrano che la Siamese è utile per apprendere una struttura di similarità e per il retrieval, ma non supera una CNN supervisionata quando l'obiettivo è la sola classificazione multiclass Top-1.

Indice

1	Introduzione	3
1.1	eccDNA e rilevanza biologica	3
1.2	Rappresentazioni alignment-free e k-mer	4
1.3	CNN, Siamese Networks e metric learning	4
2	Dataset e Preprocessing	6
2.1	Sorgenti e struttura del dataset	6
2.2	Task finale a 12 classi	6
2.3	Controllo del leakage	7
2.4	Strategie di bilanciamento	8
3	Rappresentazione FCGR	9
4	Metodologia	10
4.1	Encoder CNN V3	10
4.2	Pipeline Siamese	11
4.3	Dynamic Semi-Hard Negative Mining	11
4.4	Reference bank e ranking multiclass	12
4.5	CNN multiclass diretta	12
4.6	Metriche di valutazione	14
5	Esperimenti e Ablation	15
6	Risultati	16
6.1	Siamese downsampled: risultati pairwise	16

6.2	Da prototype a reference bank	17
6.3	Effetto dell'uso del training set completo	18
6.4	Baseline CNN multiclass	19
6.5	Confronto dei tre modelli	19
6.6	Prestazioni per classe	20
6.7	Confusion matrix e analisi delle confusioni	20
6.8	Analisi dello spazio latente	22
7	Conclusioni	24
7.1	Limiti	24
7.2	Sviluppi futuri	25
7.3	Epilogo	25

Capitolo 1

Introduzione

1.1 eccDNA e rilevanza biologica

Il DNA extracromosomico circolare (*eccDNA*) comprende molecole di DNA circolare che originano dal genoma cromosomico ma si trovano al di fuori dei cromosomi. Queste molecole sono state osservate sia in tessuti normali sia in condizioni patologiche. In ambito oncologico, alcune forme di DNA extracromosomico possono contribuire all'amplificazione di oncogeni, all'eterogeneità intratumorale e alla rapida evoluzione del tumore, con possibili effetti sulla resistenza ai trattamenti e sulla prognosi [7, 5].

È importante distinguere l'associazione biologica dalla casualità: la presenza di eccDNA non implica automaticamente la presenza di una patologia. Per questo motivo il dataset utilizzato comprende anche campioni associati a individui sani (Healthy). Il problema studiato non è quindi "eccDNA contro non-eccDNA", bensì l'apprendimento di pattern composizionali delle sequenze eccDNA che possano essere associati a specifiche classi biologiche.

Negli ultimi anni, lo sviluppo di tecniche di sequenziamento ad alta produttività ha aumentato rapidamente il numero di eccDNA identificati e annotati. Database come eccDNABase e CircleBase V2 raccolgono informazioni su coordinate genomiche, tessuti, cell-line, malattie e metodi di identificazione, rendendo possibile lo sviluppo di modelli data-driven su larga scala [8, 6].




Figura 1.1.1: eccDNA

1.2 Rappresentazioni alignment-free e k -mer

Un k -mer è una sottosequenza di lunghezza k e l'insieme delle frequenze dei k -mer descrive la composizione locale di una sequenza senza richiedere un allineamento esplicito. Questa caratteristica rende i metodi basati su queste sottosequenze particolarmente adatti a dataset genomici ampi ed eterogenei nei quali l'allineamento tra tutte le sequenze sarebbe costoso e/o poco informativo.

La Chaos Game Representation (CGR), introdotta per l'analisi di sequenze genomiche da Jeffrey [4], trasforma una sequenza di DNA in una rappresentazione bidimensionale. La Frequency Chaos Game Representation (FCGR) discretizza questo spazio e associa a ciascuna cella la frequenza di uno specifico k -mer. ne risulta una matrice $2^k \times 2^k$ che può essere trattata come un'immagine a singolo canale.

La combinazione FCGR+CNN è già stata impiegata con successo per la classificazione di sequenze genomiche; ad esempio, Cartes et al. [1] hanno mostrato che una CNN applicata a FCGR può discriminare clade di SARS-CoV-2 e recuperare pattern di k -mer informativi. In questo progetto lo stesso principio di rappresentazione viene applicato alle sequenze eccDNA, ma con un obiettivo di metric learning.

1.3 CNN, Siamese Networks e metric learning

Le Convolutional Neural Networks (CNN) apprendono filtri locali condivisi e sono naturalmente adatte all'analisi di immagini o matrici strutturate. Nel progetto la CNN non viene

inizialmente utilizzata per produrre direttamente una delle 12 etichette, ma come encoder che mappa la FCGR in un vettore compatto.

Una Siamese Network contiene due rami con parametri condivisi: due input vengono trasformati dallo stesso encoder e confrontati nello spazio latente. Il paradigma, introdotto per l'apprendimento di metriche discriminative [2], permette di apprendere una rappresentazione nella quale esempi semanticamente simili risultino vicini e quelli differenti più lontani. La Contrastive Loss formalizza questo obiettivo imponendo una penalizzazione sulle distanze di coppie positive e negative [3].

L'obiettivo principale del progetto è quindi valutare se una rappresentazione FCGR possa contenere un segnale sufficiente a organizzare le sequenze eccDNA in uno spazio di similarità disease-aware. Su indicazione del tutor, questo obiettivo è stato successivamente affiancato da una CNN multiclass diretta, necessaria come baseline per stabilire se la Siamese porti un vantaggio reale rispetto alla classificazione supervisionata standard.

Capitolo 2

Dataset e Preprocessing

2.1 Sorgenti e struttura del dataset

Il dataset di partenza collega sequenze eccDNA a metadati biologici. I file principali sono un TSV contenente annotazioni e split e un FASTA contenente le sequenze; i due file sono collegati tramite il campo `id`. Tra i metadati sono presenti la disease associata, le coordinate genomiche, la lunghezza, il GC content, il tissue, la cell-line, la source database e lo split di appartenenza.

La versione di partenza contiene circa 3.76 milioni di record, di cui circa 445 mila associati alla classe Healthy e 3.31 milioni disease-associated. Le sorgenti principali sono CircleBaseV2 ed eccDNABase. Il progetto utilizza il campo `disease` come target multiclass e `split_cluster` come riferimento per train, validation e test, in modo da ridurre il rischio che regioni genomiche molto simili finiscano in split differenti.

2.2 Task finale a 12 classi

Dopo una fase esplorativa a 18 classi, il task è stato riformulato considerando solo le classi tumorali con un supporto sufficiente e la classe Healthy. Le 12 classi finali sono:

1. gastric cancer;
2. healthy;
3. ovarian cancer;
4. prostate cancer;
5. colorectal cancer;
6. lymphoma;
7. cervical adenocarcinoma;

8. leukemia;
9. hypopharyngeal squamous cell carcinoma;
10. glioblastoma cancer;
11. melanoma;
12. hypopharynx cancer.

Il training set completo contiene 96,167 campioni, mentre validation e test finali contengono rispettivamente 9,753 e 8,923 campioni. Il test è stato mantenuto congelato durante la scelta degli iperparametri e dei checkpoint.

Tabella 2.1: Dimensioni degli split utilizzati nel task finale.

Insieme	Numero di campioni
Train completo	96,167
Train downsampled	25,332
Validation	9,753
Test finale	8,923
Numero di classi	12

Tabella 2.2: Distribuzione delle classi nel training set completo.

Classe	Train	Classe	Train
gastric cancer	10,000	cervical adenocarcinoma	10,000
healthy	10,000	leukemia	10,000
ovarian cancer	10,000	hypopharyngeal SCC	5,052
prostate cancer	10,000	glioblastoma cancer	4,880
colorectal cancer	10,000	melanoma	4,124
lymphoma	10,000	hypopharynx cancer	2,111

2.3 Controllo del leakage

Le coppie e le triplette utilizzate negli esperimenti metric-learning sono costruite solo dopo aver applicato lo split. Una coppia positiva contiene due campioni della stessa disease, mentre una coppia negativa contiene campioni di disease differenti. Questa scelta evita di

utilizzare indirettamente nel training informazioni provenienti da validation o test. Analogamente, le reference bank usate in inferenza sono costruite esclusivamente a partire dal train.

2.4 Strategie di bilanciamento

La prima Siamese finale utilizza downsampling a 2,111 campioni per classe, pari alla numerosità della classe meno rappresentata, ottenendo 25,332 campioni. Questa configurazione rappresenta la baseline storica del progetto.

In seguito è stata addestrata una seconda Siamese mantenendo tutti i 96,167 campioni. Il bilanciamento viene realizzato a livello di batch: ogni batch contiene 5 anchor per ciascuna delle 12 classi, per un batch size complessivo di 60. Nella Siamese full-train ogni batch bilanciato contiene 5 anchor per ciascuna delle 12 classi, per un batch size complessivo di 60. Il numero di batch per epoca dipende dalla fase di training: 1,603 batch durante il warm-up e 802 batch durante il Dynamic Semi-Hard Mining. La CNN multiclass utilizza invece 2,000 batch bilanciati per epoca, corrispondenti a 10,000 esposizioni per classe.

La stessa strategia di balanced batch sampling viene utilizzata per la baseline CNN multiclass, evitando di combinare contemporaneamente sampler bilanciato e class weights nella CrossEntropy.

Capitolo 3

Rappresentazione FCGR

Sia $S = s_1 \dots s_n$ una sequenza su $\{A, C, G, T, N\}$. Per un valore fissato di k , ogni possibile k -mer formato dalle quattro basi canoniche è associato a una cella della matrice FCGR. La matrice contiene il numero, o la frequenza normalizzata, delle occorrenze del corrispondente k -mer. I k -mer che contengono basi ambigue vengono ignorati nel conteggio.

La dimensione della matrice cresce esponenzialmente con k :

$$\dim(\text{FCGR}) = 2^k \times 2^k. \quad (3.1)$$

Nel progetto sono state confrontate principalmente:

- $k = 6$: FCGR 64×64 ;
- $k = 7$: FCGR 128×128 .

Il passaggio da $k = 6$ a $k = 7$ aumenta di quattro volte il numero di celle, ma non ha prodotto un miglioramento sostanziale nel ranking multiclass. Il valore $k = 6$ è stato quindi mantenuto nella configurazione finale per il miglior compromesso tra costo computazionale e prestazioni.

Capitolo 4

Metodologia

4.1 Encoder CNN V3

Per l'encoder Siamese e per il backbone della CNN diretta viene utilizzata la stessa architettura convoluzionale. Ogni FCGR entra con shape $1 \times 64 \times 64$. L'encoder produce poi una rappresentazione di 128 dimensioni.

Tabella 4.1: Architettura dell'encoder CNN V3.

Blocco	Operazioni
Input	$1 \times 64 \times 64$
1	Conv 3×3 , $1 \rightarrow 32$, bias=False; GroupNorm(8); ReLU
2	Conv 3×3 , $32 \rightarrow 32$, bias=False; ReLU; MaxPool 2×2
3	Conv 3×3 , $32 \rightarrow 64$, bias=False; GroupNorm(8); ReLU; MaxPool 2×2
4	Conv 3×3 , $64 \rightarrow 128$, bias=False; GroupNorm(8); ReLU; MaxPool 2×2
5	Conv 3×3 , $128 \rightarrow 128$, bias=False; GroupNorm(8); ReLU
Pooling	Adaptive Average Pooling 4×4
Projection	Flatten $2048 \rightarrow 256 \rightarrow 128$ con ReLU intermedia

Mentre la Siamese applica una normalizzazione L2 all'embedding finale, la CNN diretta mantiene la rappresentazione 128D non normalizzata e aggiunge un layer lineare $128 \rightarrow 12$ che produce i logits.

4.2 Pipeline Siamese




Figura 4.2.1: Schema della Siamese Network utilizzata nel progetto. I due rami condividono esattamente gli stessi pesi.

Per due embedding z_1, z_2 si considera la distanza Euclidea

$$d = \|z_1 - z_2\|_2. \quad (4.1)$$

Il target vale $y = 1$ per coppie della stessa classe e $y = 0$ per coppie di classi differenti. La Contrastive Loss è

$$\mathcal{L} = y d^2 + (1 - y) \max(0, m - d)^2, \quad (4.2)$$

con margine $m = 1.25$.

4.3 Dynamic Semi-Hard Negative Mining

Il training Siamese è diviso in due fasi. Inizialmente le prime tre epoche utilizzano coppie positive e negative casuali. In seguito, per ogni *anchor* viene scelto un positive della stessa classe e vengono generati sei candidati negative appartenenti a classi diverse. Le negative selezionate devono soddisfare preferibilmente la condizione

$$d_+ < d_- < m. \quad (4.3)$$

In questo modo il negative è abbastanza vicino da risultare informativo, ma non così difficile da destabilizzare l'ottimizzazione. Nel caso non esistesse un candidato semi-hard viene utilizzato un fallback coerente con la distanza positiva.

La configurazione downsampled utilizza 50,000 coppie per epoca. Nella configurazione full-train il budget è stato riallineato alla dimensione dell'intero training set: 1,603 batch nel warm-up, equivalenti a 96,180 vincoli pairwise, e 802 batch nella fase di mining, equivalenti a 48,120 anchor e 96,240 vincoli pairwise considerando positive e negative selezionati.

4.4 Reference bank e ranking multiclass

Dopo il training, l'encoder viene utilizzato per estrarre gli embedding del train. Per rendere il confronto con la Siamese downsampled equo e per evitare un vantaggio dovuto al maggior numero di riferimenti delle classi più frequenti, la valutazione principale utilizza una reference bank bilanciata di 2,111 campioni per classe.

Per ogni query vengono calcolate le cosine similarity verso i riferimenti di ciascuna classe. Lo score di una classe è la media delle 20 similarity più alte. Le classi vengono poi ordinate in senso decrescente e valutate tramite Top-1, Top-3 e Top-5. Poiché gli embedding sono L2-normalizzati,

$$d_E^2 = 2 - 2 \cos(\theta), \quad (4.4)$$

quindi distanza Euclidea e cosine similarity sono monotonicamente legate. Gli score cosine non vengono interpretati come probabilità calibrate.




Figura 4.4.1: Overview della pipeline per la classificazione tramite eccDNA e Siamese Network.

4.5 CNN multiclass diretta

La baseline della CNN diretta utilizza la stessa FCGR $k = 6$, lo stesso training set completo e lo stesso backbone CNN V3. Alla rappresentazione 128D viene aggiunto un classificatore

lineare a 12 output. Il training usa CrossEntropy sui logits; il softmax viene applicato solo in inferenza per ottenere probabilità normalizzate. I principali iperparametri sono: batch size 60 con 5 campioni per classe, AdamW con learning rate 3×10^{-4} , weight decay 10^{-4} , massimo 30 epoche ed early stopping con patience 5. Il checkpoint viene selezionato sulla validation Macro-F1. Il best model viene ottenuto all'epoca 3, quando il validation Macro-F1 raggiunge 0.301661.




Figura 4.5.1: Andamento del Macro-F1 della CNN diretta. Dopo l'epoca 3 il training continua a migliorare, mentre la validation non mostra un progresso stabile; l'early stopping seleziona quindi il checkpoint dell'epoca 3.




Figura 4.5.2: Overview pipeline CNN diretta.

4.6 Metriche di valutazione

Per la Siamese vengono valutate due prospettive differenti:

- **pairwise**: ROC-AUC, accuracy, balanced accuracy e Macro-F1 nel distinguere coppie same/different;
- **multiclass retrieval**: Accuracy/Recall@1, Top-3, Top-5, Macro-F1 e versioni balanced del Top- k .

Per la CNN diretta vengono utilizzate Accuracy, Macro-F1, Balanced Accuracy, Top-3 e Top-5. La confusion matrix è normalizzata per riga, in modo che ogni riga descriva la distribuzione delle predizioni condizionata alla classe vera.

Capitolo 5

Esperimenti e Ablation

Gli esperimenti preliminari hanno valutato il ruolo della risoluzione FCGR, della loss, del negative mining e dell'architettura dell'encoder.

Tabella 5.1: Sintesi delle principali ablation sul task a 12 classi. I risultati di Transformer e ViT sono esplorativi e non equivalgono a un training completo.

Esperimento	FCGR	Modifica	Val AUC	Acc. multiclass	Macro-F1	Bal. Acc.
CNN V3 random baseline	$k = 6$	random pairs	0.6611	0.2796	0.2434	0.2953
CNN V3 semi-hard	$k = 6$	dynamic semi-hard + Top20	0.6649	0.3081	0.2869	0.3139
CNN V3 random	$k = 7$	maggiore risoluzione	0.6659	0.3031	0.2843	0.3116
Residual CNN	$k = 6$	encoder residuale	0.6570	0.2700	0.2352	0.2901
CNN + Transformer	$k = 7$	self-attention dopo CNN	~ 0.631	–	–	–
ViT from scratch	$k = 6$	encoder ViT	~ 0.628	–	–	–
Proxy regularization	$k = 6$	contrastive + class proxies	~ 0.663	0.2930	0.2750	0.3059

Le loss basate direttamente su cosine similarity non hanno superato la Contrastive Loss Euclidea. La Triplet Loss con batch-hard mining ha mostrato un comportamento di collapse degli embedding, mentre una formulazione ibrida Contrastive+Triplet non ha migliorato la qualità multiclass. Anche l'hard negative mining aggressivo ha ridotto la validation AUC; il semi-hard mining è risultato più stabile.

L'aumento da $k = 6$ a $k = 7$ ha prodotto un miglioramento pairwise molto piccolo ma nessun vantaggio coerente nel ranking multiclass. Questo suggerisce che la limitazione principale non dipenda semplicemente dalla risoluzione dell'immagine FCGR.

6.1 Siamese downsampled: risultati pairwise

Il miglior checkpoint della Siamese downsampled viene selezionato all'epoca 11 della fase di Dynamic Semi-Hard Mining, utilizzando come criterio la ROC-AUC sul validation set pairwise. Il modello raggiunge una validation ROC-AUC pari a 0.664895 e una Contrastive Loss di 0.360756. Sullo stesso insieme, la distanza Euclidea media tra coppie positive è $d_+ = 0.592685$, mentre quella tra coppie negative è $d_- = 0.703356$, con un distance gap pari a 0.110671.

La soglia di decisione per distinguere coppie appartenenti alla stessa classe da coppie di classi differenti viene determinata esclusivamente sulla validation ed è pari a 0.682004. Applicando tale soglia al test pairwise indipendente, il modello ottiene una ROC-AUC di 0.652497, una Balanced Accuracy di 0.610600 e un Macro-F1 di 0.610559.




Figura 6.1.1: Validation ROC-AUC.




Figura 6.1.2: Distanze positive e negative.




Figura 6.1.3: Distribuzione delle distanze positive e negative sul test pairwise della Siamese downsampled. La sovrapposizione delle distribuzioni spiega la ROC-AUC moderata.

6.2 Da prototype a reference bank

Rappresentare ogni classe con un unico centroide produce sulla validation Accuracy 0.288834, Macro-F1 0.247915 e Balanced Accuracy 0.301971. Una reference bank locale descrive meglio la dispersione intra-classe. L'ablation del numero di riferimenti porta a scegliere Top-20, che massimizza il Macro-F1 mantenendo accuracy e balanced accuracy comparabili al Top-50.

Tabella 6.1: Ablation del numero di riferimenti per classe nella Siamese downsampled.

Top- k refs	Accuracy	Macro-F1	Balanced Accuracy
1	0.2157	0.2107	0.2201
5	0.2850	0.2742	0.2928
10	0.2994	0.2836	0.3059
20	0.3081	0.2869	0.3139
50	0.3095	0.2824	0.3158

6.3 Effetto dell'uso del training set completo

La Siamese full-train utilizza tutti i 96,167 campioni. Dopo tre epoche di warm-up, il best checkpoint della fase semi-hard è raggiunto all'epoca 13, con validation ROC-AUC 0.670110, loss 0.359491, $d_+ = 0.591210$, $d_- = 0.706217$, gap 0.115008 e $d' = 0.598891$.




Figura 6.3.1: Validation ROC-AUC della Siamese full-train balanced. Il miglior checkpoint è all'epoca 13.

Sulla validation, il passaggio dal downsampling al full training produce piccoli miglioramenti coerenti: ROC-AUC da 0.664895 a 0.670110, Top-1 da 30.74% a 31.21%, Top-3 da 65.20% a 66.18% e Top-5 da 82.20% a 83.08%. Sul test, tuttavia, il quadro è più sfumato: Top-1 e Macro-F1 diminuiscono leggermente, mentre Top-3 e Top-5 migliorano. Il risultato mostra che mantenere tutti i dati aumenta soprattutto la qualità del ranking più profondo, senza garantire un vantaggio nella decisione Top-1




Figura 6.3.2: Confronto sul test tra Siamese downsampled e Siamese full-train balanced.

6.4 Baseline CNN multiclass

La CNN diretta viene selezionata all'epoca 3 sulla base del validation Macro-F1. In validation ottiene Accuracy 0.330052, Macro-F1 0.301661, Balanced Accuracy 0.334499, Top-3 0.673536 e Top-5 0.836358. Sul test ottiene Accuracy 0.328253, Macro-F1 0.285780, Balanced Accuracy 0.330599, Top-3 0.675894 e Top-5 0.840861.

Questi risultati superano entrambe le Siamese per la classificazione diretta. Il vantaggio rispetto alla Siamese full-train è di circa 2.14 punti percentuali in Top-1 e 1.69 punti in Macro-F1; il vantaggio resta presente anche in Top-3 e Top-5.

6.5 Confronto dei tre modelli

Tabella 6.2: Confronto finale sul test indipendente.

Modello	Train	Top-1	Macro-F1	Bal. Acc.	Top-3	Top-5	Bal. Top-3	Bal. Top-5
Siamese downsampled	25,332	0.3158	0.2784	0.3197	0.6583	0.8253	0.6561	0.8209
Siamese full-train balanced	96,167	0.306847	0.268841	0.310454	0.664799	0.833352	0.658991	0.825019
Direct CNN full-train	96,167	0.328253	0.285780	0.330599	0.675894	0.840861	0.669850	0.825723

Il confronto controllato permette di separare due domande. La prima riguarda l'effetto del bilanciamento: il full-train migliora soprattutto Top-3/Top-5 rispetto al downsampling. La seconda riguarda il paradigma di apprendimento: quando l'obiettivo è assegnare direttamente una delle 12 classi, la CNN supervisionata è complessivamente migliore della Siamese.

6.6 Prestazioni per classe





Figura 6.6.1: Recall@1 per classe sul test. Le tre configurazioni condividono diverse classi difficili, in particolare prostate cancer.

La CNN migliora il Recall@1 di gastric cancer (54.5%), ovarian cancer (54.8%), lymphoma (48.3%) e leukemia (27.7%) rispetto alla Siamese full-train. Melanoma è la classe più facile per tutti i modelli, con Recall@1 attorno al 66–67%. Prostate cancer rimane invece estremamente difficile: il Recall@1 è 9.7% nella Siamese downsampled, 8.0% nella Siamese full-train e 7.3% nella CNN. Il fatto che la stessa classe rimanga problematica con obiettivi di training differenti suggerisce una limitata separabilità nella rappresentazione FCGR, non unicamente un problema della loss Siamese.

6.7 Confusion matrix e analisi delle confusioni


Di seguito vengono riportate confusion matrix complete per verificare quali classi vengano confuse sistematicamente. Le matrici normalizzate per classe vera permettono di confrontare classi con supporti differenti.

6. RISULTATI



(a) Siamese downsampled.

(b) Siamese full-train balanced.



(c) CNN multiclass diretta.

Figura 6.7.1: Confusion matrix normalizzate sul test set per le tre configurazioni considerate.

L'analisi quantitativa delle principali celle fuori diagonale evidenzia errori non casuali. La coppia più critica è prostate cancer→ovarian cancer: 30.8% nella Siamese full-train e 33.8% nella CNN. Anche hypopharyngeal SCC e hypopharynx cancer vengono confuse in entrambe le direzioni. La CNN riduce alcune confusioni strutturali, come glioblastoma→leukemia e colorectal→cervical, ma ne accentua altre, in particolare cervical adenocarcinoma→gastric cancer e cervical adenocarcinoma→lymphoma.

Tabella 6.3: Confronto di alcune delle principali confusioni sul test. Le percentuali sono riferite alla classe vera.

Confusione	Siamese full-train	Direct CNN
prostate $\rightarrow$ ovarian	30.80%	33.80%
hypopharyngeal SCC $\rightarrow$ hypopharynx	29.86%	22.57%
hypopharynx $\rightarrow$ hypopharyngeal SCC	21.05%	19.30%
glioblastoma $\rightarrow$ leukemia	21.96%	18.92%
leukemia $\rightarrow$ glioblastoma	14.40%	9.00%
colorectal $\rightarrow$ cervical	19.00%	10.40%
cervical $\rightarrow$ colorectal	16.90%	17.40%
healthy $\rightarrow$ melanoma	21.90%	20.90%
cervical $\rightarrow$ gastric	21.00%	26.10%
cervical $\rightarrow$ lymphoma	20.30%	25.30%

Le coppie hypopharyngeal SCC/hypopharynx, glioblastoma/leukemia, colorectal/cervical e ovarian/prostate erano già emerse come coppie di centroidi vicini nello spazio latente della Siamese. La coerenza tra geometria degli embedding e confusion matrix supporta l'interpretazione secondo cui una parte degli errori deriva da una sovrapposizione strutturale delle rappresentazioni apprese.

6.8 Analisi dello spazio latente

Per verificare se la proiezione a 128 dimensioni fosse il principale collo di bottiglia, sono state confrontate tre rappresentazioni interne dello stesso encoder: feature CNN 2048D, hidden representation 256D ed embedding finale 128D. Tutte sono state L2-normalizzate prima dell'analisi.

Tabella 6.4: Geometria delle rappresentazioni interne della Siamese downsampled.

Spazio	Intra dist.	Nearest centroid	Mean sep. ratio	Median sep. ratio	Classi > 1
2048D	0.6605	0.2273	0.3688	0.2711	1
256D	0.5950	0.2028	0.3628	0.2670	1
128D	0.4310	0.1458	0.3545	0.2784	1

Il separation ratio è definito come la distanza dal centroide della classe più vicina divisa per la dispersione intra-classe media. Un valore minore di 1 indica che il centroide concorrente

è più vicino della dispersione tipica all'interno della classe. In 11 classi su 12 il rapporto è inferiore a 1; solo melanoma supera 1.

La stessa conclusione emerge dal ranking Top-20 sui tre livelli: 2048D raggiunge Accuracy 0.3055, 256D 0.3055 e 128D 0.3082. La compressione finale non è quindi la causa principale della sovrapposizione: il fenomeno è già presente nelle feature convoluzionali ad alta dimensionalità.

Capitolo 7

Conclusioni

I risultati permettono di rispondere a tre punti principali

Uso del training set completo. La strategia full-train con balanced batch sampling evita di eliminare campioni delle classi maggioritarie. In validation migliora tutte le metriche della Siamese, compresa la pairwise ROC-AUC. Sul test, tuttavia, il guadagno si concentra sul ranking Top-3/Top-5, mentre Top-1 e Macro-F1 rimangono leggermente inferiori alla configurazione downsampled. L'uso di più dati è quindi utile, ma non risolve la sovrapposizione tra classi.

Baseline multiclass diretta. La CNN diretta è il miglior modello se la metrica di interesse è la classificazione a 12 classi. La differenza non è enorme, ma è coerente tra validation e test. Questo risultato indica che la Siamese non offre un vantaggio predittivo diretto quando le classi sono note a priori e sono disponibili etichette sufficienti.

Valore della Siamese. Il metric learning mantiene comunque una funzione diversa dalla CNN multiclass. La Siamese produce uno spazio di embedding riutilizzabile per confronto tra campioni, retrieval e ranking di similarità. La classe vera compare nel Top-3 nel 65–66% dei campioni e nel Top-5 in oltre l'82%, mostrando che l'informazione disease-aware è presente anche quando il Top-1 è incerto.

Un punto centrale riguarda le confusioni. Prostate/ovarian, hypopharyngeal SCC/hypopharynx e glioblastoma/leukemia rimangono difficili con modelli differenti. Questo comportamento, insieme all'analisi dei centroidi, suggerisce che la limitazione non sia riconducibile a un unico iperparametro o a una singola loss. Possibili cause includono somiglianze composizionali delle sequenze, eterogeneità interna delle disease label, differenze di tissue/source database e informazione biologica non catturata dalla sola sequenza dell'intervallo eccDNA.

7.1 Limiti

- Le classi rappresentano associazioni disease-aware dei record eccDNA e non devono essere interpretate come diagnosi causali.
- La separazione delle classi nello spazio FCGR resta moderata; la Top-1 massima è circa

33%.

- Healthy presenta recall relativamente basso e può includere forte eterogeneità biologica.
- Il balanced batch sampling ripete più spesso le classi minoritarie; ciò corregge l'esposizione di classe ma non crea nuova diversità biologica.
- La reference bank bilanciata è un protocollo di valutazione scelto per evitare bias da numerosità; una bank completa potrebbe introdurre un vantaggio statistico alle classi con più riferimenti.
- Le ablation $k = 8, 9, 10$ non sono state completate nel task finale; $k = 6$ e $k = 7$ hanno mostrato risultati molto simili.

7.2 Sviluppi futuri

Sviluppi successivi potrebbero considerare split più severi per tissue, cell line o source database, in modo da verificare la capacità del modello di generalizzare a contesti biologici non osservati. Un'altra direzione è integrare informazioni addizionali, come la lunghezza dell'eccDNA, il GC content, le coordinate genomiche o le annotazioni funzionali, evitando però che tali variabili diventino scorciatoie rispetto alla disease.

Per il metric learning, si potrebbero valutare strategie self-supervised o pretraining su un corpus più ampio di FCGR e successivo fine-tuning disease-aware. Dal punto di vista biologico, le classi che mostrano confusioni persistenti meritano un'analisi specifica per capire se condividano tissue, protocolli sperimentali o proprietà composizionali dei k -mer.

7.3 Epilogo

Il progetto ha costruito e valutato una pipeline completa per l'analisi di sequenze eccDNA tramite FCGR e deep learning. La configurazione Siamese più stabile utilizza FCGR $k = 6$, encoder CNN V3, embedding L2-normalizzato a 128 dimensioni, Contrastive Loss Euclidea e Dynamic Semi-Hard Negative Mining. Il passaggio dal downsampling al training completo con balanced batch sampling migliora la validation ROC-AUC e il ranking Top-3/Top-5, ma non produce un vantaggio Top-1 sul test.

Il confronto diretto mostra che la CNN multiclass con lo stesso backbone e lo stesso training set completo ottiene le migliori prestazioni complessive: 32.83% Top-1, 28.58% Macro-F1, 33.06% Balanced Accuracy, 67.59% Top-3 e 84.09% Top-5. La Siamese non è quindi superiore come classificatore hard a 12 classi.

Il risultato non annulla tuttavia il valore del metric learning. Le Siamese apprendono una geometria disease-aware utilizzabile per similarity search e retrieval; inoltre l'analisi dello

spazio latente rende esplicite le coppie di classi che risultano strutturalmente sovrapposte. Il contributo principale del lavoro è pertanto duplice: da un lato stabilisce una baseline controllata per la classificazione FCGR delle sequenze eccDNA, dall'altro mostra limiti e potenzialità di una rappresentazione Siamese quando il problema viene formulato come associazione per similarità anziché come sola decisione Top-1.

Bibliografia

- [1] J. Avila Cartes et al. “Accurate and fast clade assignment via deep learning and frequency chaos game representation”. In: *GigaScience* 12 (2023), giac119. DOI: 10.1093/gigascience/giac119. URL: <https://doi.org/10.1093/gigascience/giac119>.
- [2] S. Chopra, R. Hadsell e Y. LeCun. “Learning a Similarity Metric Discriminatively, with Application to Face Verification”. In: *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition*. 2005, pp. 539–546. DOI: 10.1109/CVPR.2005.202. URL: <https://doi.org/10.1109/CVPR.2005.202>.
- [3] R. Hadsell, S. Chopra e Y. LeCun. “Dimensionality Reduction by Learning an Invariant Mapping”. In: *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition*. 2006, pp. 1735–1742. DOI: 10.1109/CVPR.2006.100. URL: <https://doi.org/10.1109/CVPR.2006.100>.
- [4] H. J. Jeffrey. “Chaos game representation of gene structure”. In: *Nucleic Acids Research* 18.8 (1990), pp. 2163–2170. DOI: 10.1093/nar/18.8.2163. URL: <https://doi.org/10.1093/nar/18.8.2163>.
- [5] Z. Li e D. Qian. “Extrachromosomal circular DNA (eccDNA): from carcinogenesis to drug resistance”. In: *Clinical and Experimental Medicine* (2024). DOI: 10.1007/s10238-024-01348-6. URL: <https://doi.org/10.1007/s10238-024-01348-6>.
- [6] Ling Wei et al. “CircleBase V2: an eccDNA annotation platform across cancers and species”. In: *Nucleic Acids Research* 54.D1 (2026), pp. D66–D77. DOI: 10.1093/nar/gkaf1266. URL: <https://doi.org/10.1093/nar/gkaf1266>.
- [7] X. Yan, P. Mischel e H. Chang. “Extrachromosomal DNA in cancer”. In: *Nature Reviews Cancer* 24 (2024), pp. 261–273. DOI: 10.1038/s41568-024-00669-8. URL: <https://doi.org/10.1038/s41568-024-00669-8>.
- [8] J.-H. Zhang et al. “eccDNABase: A Comprehensive and High-Quality Database for Extrachromosomal Circular DNA”. In: *Molecular Biology and Evolution* 42.10 (2025), msaf223. DOI: 10.1093/molbev/msaf223. URL: <https://doi.org/10.1093/molbev/msaf223>.